### Reconnaissance d'écriture manuscrite

cours M2 ATAL

Adeline GRANET : adeline.granet@gmail.com

23 novembre 2020

### Qui suis-je?

- Master recherche ATAL (2013-2015)
- Stage de fin d'étude : création d'un prototype de chatbot pour la Maif (2015)
- Thèse à l'Univ. Nantes: "Extraction d'information sur des documents anciens" dirigée par Emmanuel Morin, et encadrée par Solen Quiniou et Harold Mouchère => soutenue le 12 décembre 2018
- Aujourd'hui: Peevee (joinverture entre Manpower-Experis et Verteego):
   création d'un chatbot pour faire du support IT (incluant du machine learning)

# Contexte applicatif

Contexte?

### Contexte applicatif

#### Contexte:

- analyse automatique des chèques
- la reconnaissance automatique des adresses postales
- la classification des demandes administratives → adresser une requête au bon service
- classification, organisation du patrimoine ⇒ démarche d'humanité numérique

## Contexte applicatif

#### Contexte:

- analyse automatique des chèques
- la reconnaissance automatique des adresses postales
- la classification des demandes administratives → adresser une requête au bon service
- classification, organisation du patrimoine ⇒ démarche d'humanité numérique

#### Particularités:

- redondances des informations dans des zones peu variantes
- vocabulaire fermé : chiffres, noms de rues, de villes

## Système de reconnaissance d'écriture manuscrite

#### 1/ Définition:

- un système automatique est construit pour répondre à 1 tâche donnée
- un apprentissage s'effectue à partir d'exemples pour généraliser la connaissance
- un exemple est une association entre 1 forme et 1 étiquette (caractère, mot)

#### 2/ Fonctionnement:

un apprentissage et évaluation du modèle à partir d'une "vérité terrain"

### Système de reconnaissance d'écriture manuscrite

1/ Définition

#### 2/ Fonctionnement:

apprentissage et évaluation du modèle à partir d'une "vérité terrain"

### 3/ Problématique:

- avec nouvelles ressources constituées de milliers de pages
- une très grande quantité d'information qui est diversifiée

### Première question

Vous êtes sur un nouveau projet, avec une toute nouvelle collection de documents manuscrits à étudier, quelle solution est envisageable ?

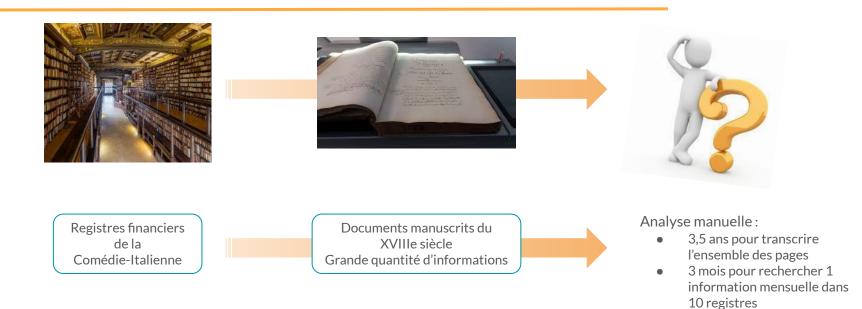


- définition d'un nouveau système de reconnaissance d'écriture dédié
- spécialisation d'un système existant avec un échantillon des données
- une autre option?

# Contexte historique

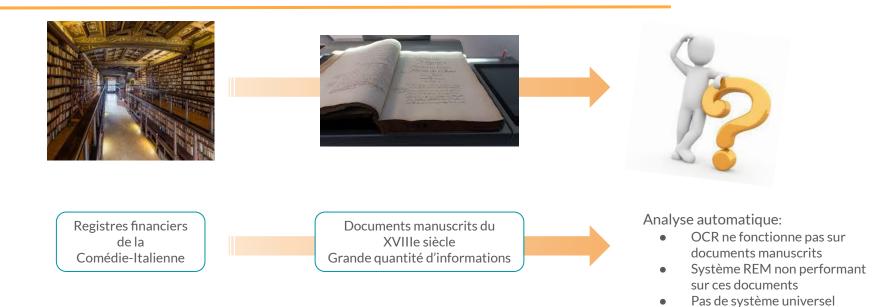


### Contexte historique



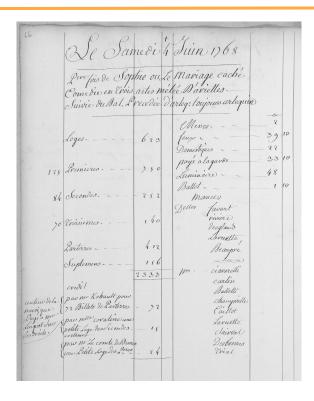
Exemple concret : Projet ANR Contrainte et Intégration : pour une **Ré**évaluation des **S**pectacles Forains et Italiens sous l'Ancien Régime

## Contexte historique

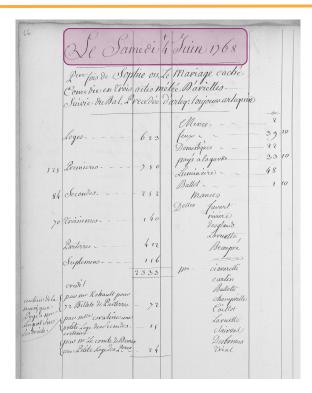


Exemple concret : Projet ANR Contrainte et Intégration : pour une **Ré**évaluation des **S**pectacles Forains et Italiens sous l'Ancien Régime

- Période : 1716 à 1793
- 63 registres financiers ⇒ 63 saisons
- Différentes informations : les recettes, les dépenses, les acteurs et employés de la troupe, et d'autres informations contextuelles sur l'époque
- 7 types de pages identifiés : comptes journaliers, mensuels et annuels, pages blanches, couvertures, et état des pensionnaires

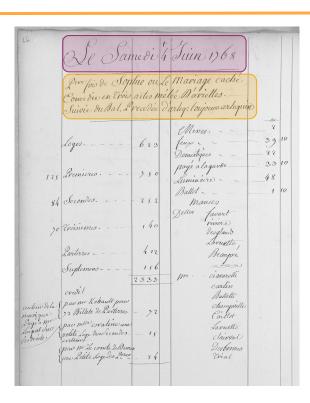


Date



Date

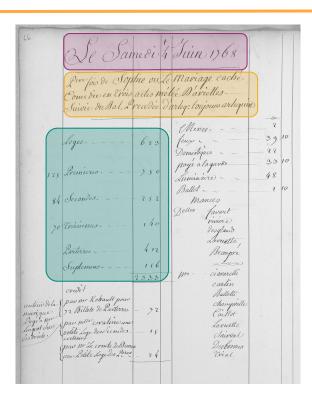
Titre



Date

Titre

Recettes

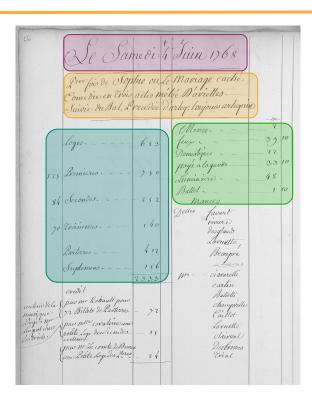


Date

**Titre** 

Recettes

Dépenses



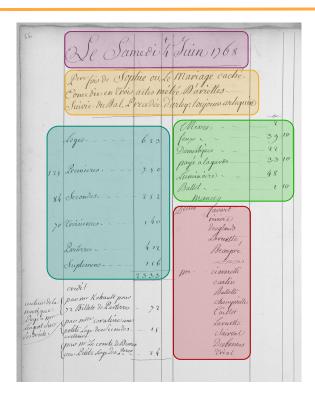
Date

**Titre** 

Recettes

Dépenses

**Acteurs** 



Date

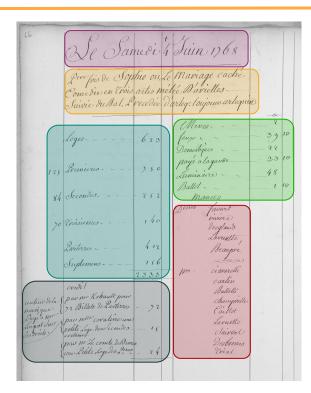
Titre

Recettes

Dépenses

**Acteurs** 

**Notes** 



Date

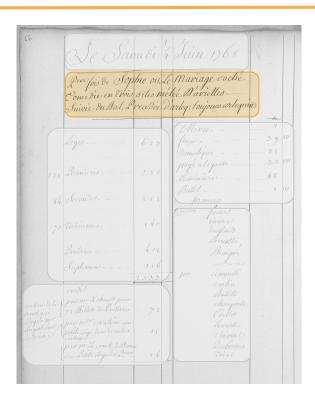
Titre

Recettes

Dépenses

Acteurs

Notes



#### Tâche coûteuse ⇒ Focus sur Titre

- Différentes informations : titres + contexte (vocabulaires différents)
- Difficulté dans la représentation
- Informations sur les titres disponibles

## Difficultés des registres

### Détection et segmentation

- Divers types de documents
- Mises en pages variées

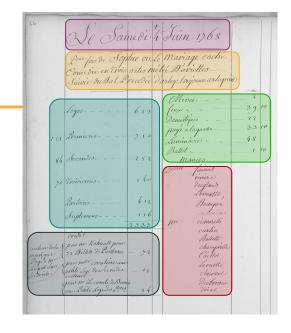
### Difficultés des registres

### Détection et segmentation

- Divers types de documents
- Mises en pages variées

### Verrous scientifiques pour la reconnaissance d'écriture

- Documents anciens
- Beaucoup de données ~27 000 pages
- Plusieurs scripteurs selon les registres
- Multilingues : dialectes italiens, français
- Dispositions et informations changeantes
- Majoritairement construits avec des entitées nommées : "Raton et Rosette"



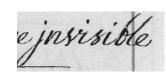
## Difficultés des registres

### Verrous scientifiques pour la reconnaissance d'écriture

- Documents anciens
- Beaucoup de données ~27 000 pages
- Plusieurs scripteurs : varie selon les registres
- Multilingues : dialectes italiens, français
- Dispositions et informations changeantes
- Majoritairement construits avec des entitées nommées : "Raton et Rosette"
- Caractères spéciaux et abréviations :



Rose





arleg?

Se Samedi 4 Juin 1768

(b) Invisible

c) Etc.





## Objectifs

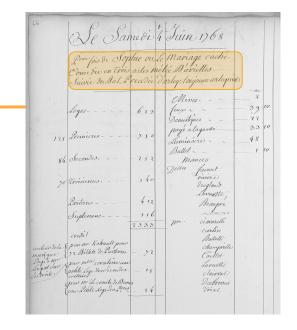
Vous êtes sur un nouveau projet, avec une toute nouvelle collection de documents manuscrits à étudier, quelle solution est envisageable ?



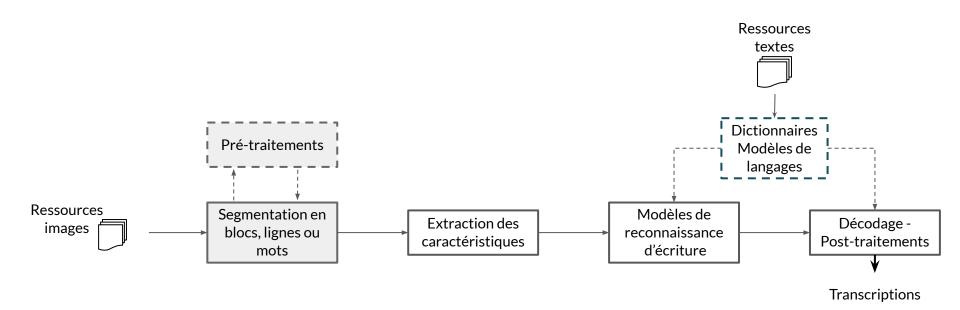
- définition d'un nouveau système de reconnaissance d' écriture dédié
- spécialisation d'un système existant avec un échantillon des données
- une autre option?

Étudier et analyser automatiquement les titres des comptes quotidiens

⇒ Sans vérité terrain



### Sommaire



### Pré-traitements

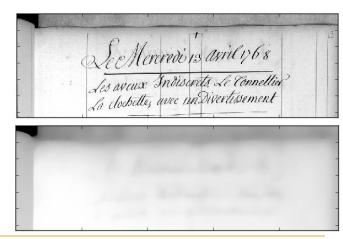
⇒ éliminer les défauts liés à l'image numérisée afin de faciliter la reconnaissance

### 2 types:

- la chaine de numérisation est responsable (inclinaison, luminosité, bruit, ...)
- la qualité intrinsèque du document est responsable (tâche d'humidité, de bougie, apparition du verso, des trous...)

• Conversion RGB vers niveau de gris

- Conversion RGB vers niveau de gris
- Suppression du bruit i.e. le fond de l'image
  - o par filtre passe-haut, passe-bas, ou morphologique <sup>1</sup>



<sup>1.</sup> Ketata, Dalel et Maher Khemakhem (2010). « Un survol sur l'analyse et la reconnaissance de documents : imprimé, ancien et manuscrit ». In : Colloque International Francophone sur l'Ecrit et le Document (CIFED2010)

- Conversion RGB vers niveau de gris
- Suppression du bruit i.e. le fond de l'image
  - par filtre passe-haut, passe-bas, ou morphologique <sup>1</sup> afin de différencier et supprimer les éléments superflus
  - des méthodes (comme Particle Swarm Optimization) combinant des filtres bilatéraux et des algorithmes, ou par variation totale qui construit une image intermédiaire utilisée comme masque <sup>2,3</sup>

<sup>1.</sup> Ketata, Dalel et Maher Khemakhem (2010). « Un survol sur l'analyse et la reconnaissance de documents : imprimé, ancien et manuscrit ». In : Colloque International Francophone sur l'Ecrit et le Document (CIFED2010)

<sup>2.</sup> Quraishi, Md Iqbal et al. (2013). « A novel hybrid approach to restore historical degraded documents ». In: Intelligent Systems and Signal Processing (ISSP), 2013 International Conference on. IEEE

<sup>3.</sup> Likforman-Sulem, Laurence, Jérôme Darbon et Elisa H Barney Smith (2011).« Enhancement of historical printed document images by combining total variation regularization and non-local means filtering ». In: Image and vision computing

- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation: conversion de l'image en niveau de gris en noir et blanc
  - o def : séparation distincte en 2 classes le fond de l'encre
  - o méthode :
    - filtres gaussiens avec la définition d'un seuil d'intensité global appelé Otsu<sup>1</sup>
    - alternatives locales <sup>2,3,4</sup> en cas de documents dégradés localement

<sup>1.</sup> Otsu, Nobuyuki (1975). « A threshold selection method from gray-level histograms ». In: Automatica 11.285-296, p. 23-27 (cf. p. 22)

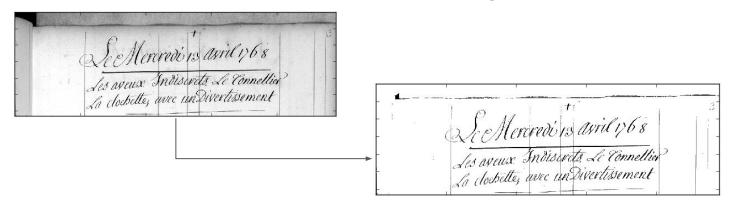
<sup>.</sup> Gatos, Basilios, Ioannis Pratikakis et Stavros J Perantonis (2006). « Adaptive degraded document image binarization ». In: Pattern recognition 39.3, p. 317-327

<sup>3.</sup> Gatos, Basilios (2008). « Efficient binarization of historical and degraded document images ». In: Document Analysis Systems, 2008. DAS'08. The Eighth IAPR International Workshop on. IEEE, p. 447-454

<sup>4.</sup> Shi, Zhixin et Venu Govindaraju (2004). « Historical document image enhancement using background light intensity normalization ». In: Pattern Recognition, 2004. ICPR 2004. Proceedings of the 17th International Conference on. T. 1.IEEE

<sup>5.</sup> Su, Bolan, Shijian Lu et Chew Lim Tan (2010). « Binarization of historical document images using the local maximum and minimum ». In: Proceedings of the 9th IAPR International Workshop on Document Analysis Systems. ACM. p. 159-166

- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation: conversion de l'image en niveau de gris en noir et blanc
  - o def : séparation distincte en 2 classes le fond de l'encre
  - o méthode :
    - filtres gaussiens avec la définition d'un seuil d'intensité global appelé Otsu<sup>1</sup>
    - alternatives locales <sup>2,3,4</sup> en cas de documents dégradés localement



- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation : conversion de l'image en niveau de gris en noir et blanc

Alternative : Classification des pixels pour extraire l'encre du fond par CAE ou K-means

#### Limites:

- Risques de perdre des pixels d'encre fondus dans le fond
- Contour du document dans l'image suivant la couleur peut influencer les différentes techniques

- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation
- Correction des lignes de texte (*skew*): corriger l'inclinaison des lignes de bases
  - o méthodes:
    - projection horizontale des profils (Vinciarelli et Luettin 2001)

      -8°

      Les aveux Inviscrets, Le Roy et a lermier avec un Eurorissement

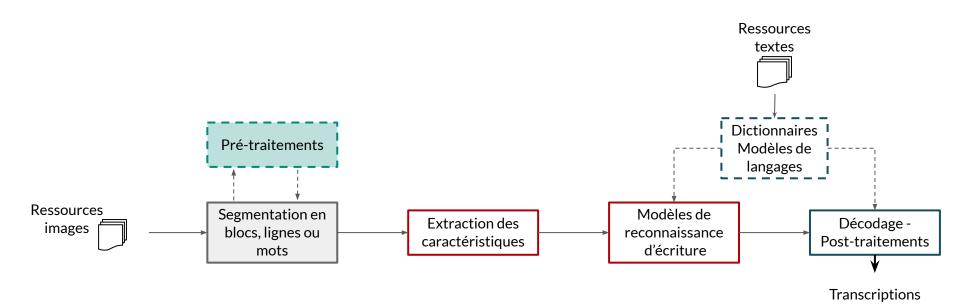
- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation
- Correction des lignes de texte (skew): corriger l'inclinaison des lignes de bases
  - o méthodes:
    - projection horizontale des profils (Vinciarelli et Luettin 2001)
    - par interpolation des contours (Bozinovic et Srihari 1989)
    - par estimation de la ligne de base au niveau mot ou au niveau de la ligne (Lemaitre et al. 2009,2011; Boukharouba 2017)
    - par correction locale (Espana-Boquera et al. 2011)
    - par une comparaison de l'ensemble des méthodes existantes (Rehman et Saba 2011)

- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation
- Correction des lignes de texte
- Correction de l'inclinaison de l'écriture (slant) : effacer les différences entre les scripteurs
  - o méthodes:
    - i. une estimation de l'angle est effectuée globalement ou localement
    - ii. l'image du texte est modifiée, généralement par cisaillement

- Conversion RGB vers niveau de gris
- Suppression du bruit : le fond de l'image
- Binarisation
- Correction des lignes de texte
- Correction de l'inclinaison de l'écriture
- Normalisation de la hauteur de l'écriture i.e. fixer les zones de hampes et de jambages et la zone centrale à une certaine hauteur



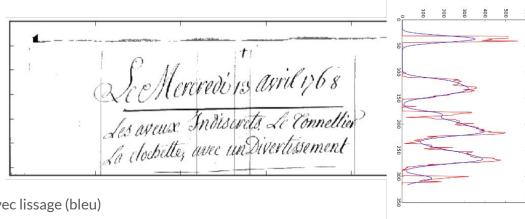
#### Sommaire



Différents types de segmentations : bloc, ligne, mot

#### Méthodes:

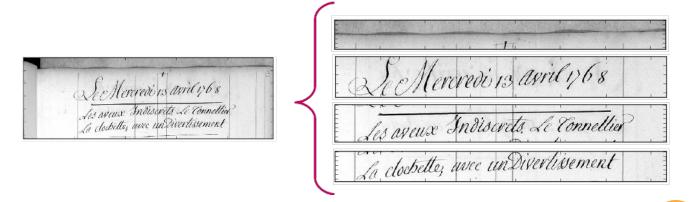
segmentation en ligne par projection des pixels



Différents types de segmentations : bloc, ligne, mot

#### Méthodes:

• segmentation en ligne par projection des pixels



Différents types de segmentations : bloc, ligne, mot

#### Méthodes:

- segmentation en ligne par projection des pixels
- regroupement de composantes connexes (avec une extraction de points d'intérêts, avec des projections de pixels et des HMMs, en utilisant la topologie des documents)

Différents types de segmentations : bloc, ligne, mot

#### Méthodes:

- segmentation en ligne par projection des pixels
- regroupement de composantes connexes (avec une extraction de points d'intérêts, avec des projections de pixels et des HMMs, en utilisant la topologie des documents)

#### Limites:

- croisement entre les hampes et jambages de lignes connexes
- présence de filets potentiellement

Différents types de segmentations : bloc, ligne, mot

#### Méthodes:

- segmentation en ligne par projection des pixels
- regroupement de composantes connexes (avec une extraction de points d'intérêts, avec des projections de pixels et des HMMs, en utilisant la topologie des documents)
- modèles hybrides combinant MLP et NN (non supervisé), NN (supervisé)

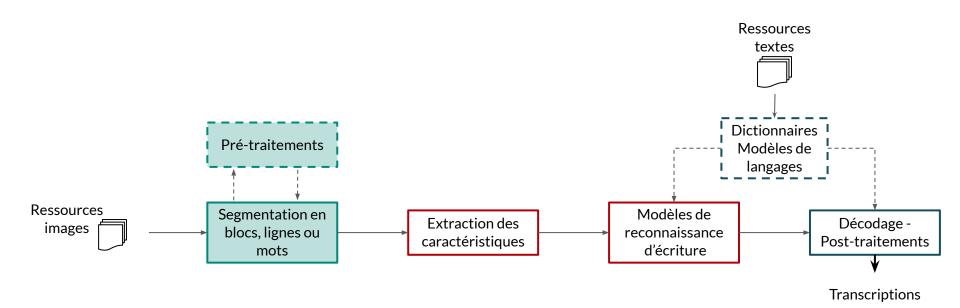
Différents types de segmentations : bloc, ligne, mot

#### Méthodes:

- segmentation en ligne par projection des pixels
- regroupement de composantes connexes (avec une extraction de points d'intérêts, avec des projections de pixels et des HMMs, en utilisant la topologie des documents)
- modèles hybrides combinant MLP et NN (non supervisé), NN (supervisé)

De moins en moins utilisé et nécessaire!

#### Sommaire



- transformation de l'image 2D en un vecteur de valeurs numériques par segment de l'image
- zone:
  - o se base sur une fenêtre glissante : à largeur fixe, et à hauteur fixe ou adaptée
  - o par segmentation de caractères, ou graphèmes
  - image complète

Caractéristiques ⇒ se base sur la valeur direct des pixels

Caractéristiques structurelles ⇒ agencement des pixels les uns par rapport aux autres

- nombre de transition observée entre l'écriture et l'arrière-plan
- nombre de pixels d'encre observés
- position des contours supérieurs et inférieurs dans la fenêtre
- moyenne des valeurs des pixels
- position du centre de gravité
- position des lignes bases (ou références)

Caractéristiques statistiques et directionnelles ⇒ permet l'orientation des traits par la construction d'histogrammes orientés

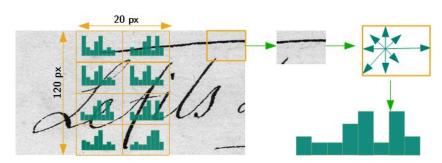
- SIFT : une transformation de caractéristiques invariante à l'échelle
  - o détection de points clés dans l'image par convolution à partir d'une gaussienne
  - calcul du gradient pour chaque point clé
  - construction de l'histogramme des orientations à 360°

Caractéristiques statistiques et directionnelles ⇒ permet l'orientation des traits par la construction d'histogrammes orientés

- SIFT : une transformation de caractéristiques invariante à l'échelle
- HOG:
  - o calcul du gradient pour l'ensemble des points de l'image regroupé par bloc ou sur l'image globale
  - o construction de l'histogramme des orientations







Caractéristiques par apprentissage

- ⇒ extraction non supervisée des caractéristiques sans connaissances à priori
- ⇒ représentation de l'image à différentes échelles

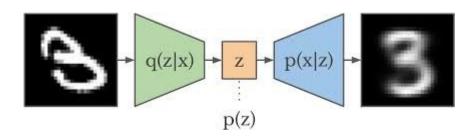
#### Caractéristiques par apprentissage

- réseaux de neurones simples
- réseaux de neurones à convolution (CNN) : très utilisé en *Vision Object*, taches très diverses (classification, détection d'objet, segmentation, ...)
  - entrée : objet en 2D ou 3D
  - structure : ens. de filtres (3 ou 5 pixels de largeur et hauteur)
  - calcule du produit scalaire des pixels de la fen. ⇒ carte d'activation en 2D
  - hyper-paramètre : chevauchement de la fenêtre glissante, création d'une marge autour de l'image
  - o un filtre = ensemble de caractéristiques à une échelle différente selon la position dans le réseau
  - o avantage : partage des poids des neurones d'une même couche

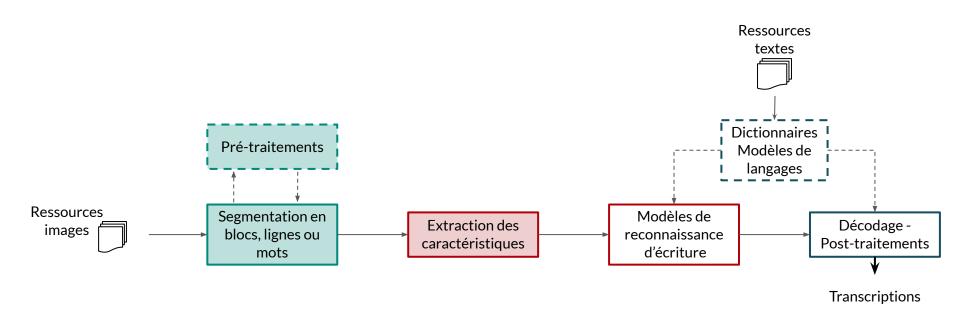
⇒ souvent associé à un sous-échantillonnage *Pooling* : évite le sur-apprentissage et réduit temps de

#### Caractéristiques par apprentissage

- réseaux de neurones simples
- réseaux de neurones à convolution (CNN) : très utilisé en *Vision Object*, taches très diverses (classification, détection d'objet, segmentation, ... )
- réseaux de type auto-encodeurs à variation, à convolution



#### Sommaire



#### Modèle de reconnaissance d'écriture

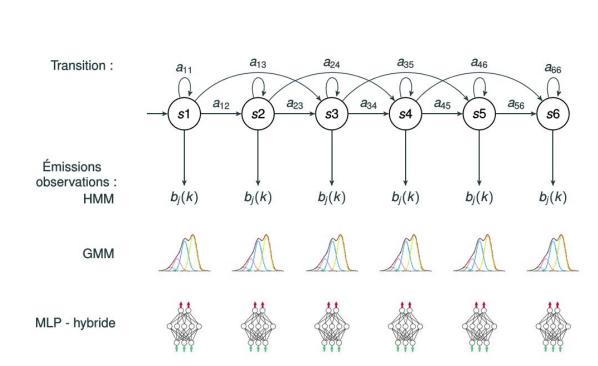
- Fin des années 90 : les modèles de Markov caché (HMM)
- Début des années 2000 : systèmes hybrides neuro-markoviens
- ⇒ pouvoir discriminant : mieux modéliser le caractère local et global de l'écriture
  - Depuis 2009 à maintenant : réseaux récurrents
- ⇒ intègrent encore mieux le mixte du local et du global, avec des effets de contexte, pour optimiser une décision sur une séquence complète

### Approches stochastiques

#### • HMM:

- un modèle probabiliste qui modélise et reconnaît des séquences temporelles
- doublement stochastique
  - proba état vers état
  - proba d'observation
- entrée : vecteur de caractéristiques

⇒ maximiser la probabilité d'observation d'une séquence émise par les états cachés



### Approches stochastiques

#### HMM:

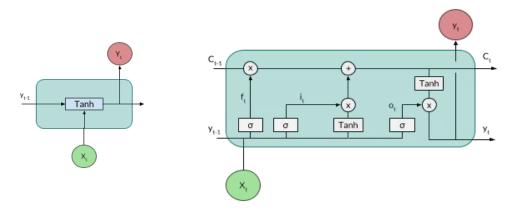
- o un modèle probabiliste qui modélise et reconnaît des séquences temporelles
- doublement stochastique
  - proba état vers état
  - proba d'observation
- o entrée : vecteur de caractéristiques
- o maximiser la probabilité d'observation d'une séquence émise par les états cachés
- deux approches :
  - globale : n modèles pour n mots
  - analytique : un modèle par caractère ⇒ concaténation pour former des mots
- ⇒ attention à la segmentation et le nombre d'états par modèle : problème de ligature
- ⇒ modèle de mots : limité sur les mots reconnus mais extraction précise pour des mots clés

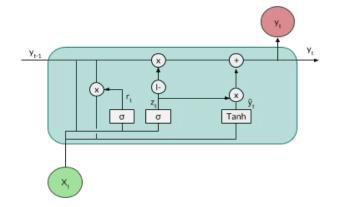
- Réseau de neurones récurrents (RNN) ⇒ un grand nombre d'avantage
  - robustesse au bruit
  - pas de connaissances a priori nécessaire
  - la mémoire du neurone permet de prendre le contexte ⇒ augmente les performances
  - $\circ$  méthode de la rétro-propagation du gradient (Werbos 1990) par itération  $\to$  converger vers un minimum global

#### ⇒ Limites :

- le gradient diminue rapidement au point de disparaître (*Vanishing gradient*) donc une prise en compte du contexte proche uniquement
- les poids d'apprentissage en grande quantité nécessitent des données suffisantes (sur-apprentissage)

- Réseau de neurones récurrents (RNN)
  - ⇒ pour résoudre le problème du gradient





a) neurone récurrent

b) neurone Long Short Term Memory

C) neurone Gated Recurrent Unit

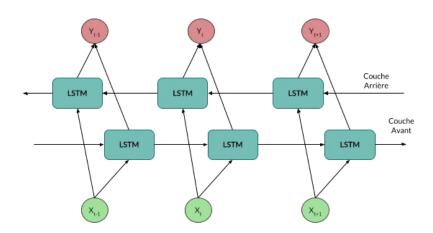
- Réseaux de neurones récurrents (RNN)
- Réseaux de neurones xDimensionnels ⇒ considère l'information passée et future

ex: pour un caractère donné, prise en compte des caractères précédents et suivants



- Réseaux de neurones récurrents (RNN)
- Réseaux de neurones xDimensionnels
  - BRNN
  - o BLSTM

Architecture : 2 couches indépendantes durant l'apprentissage



- Réseaux de neurones récurrents (RNN)
- Réseaux de neurones xDimensionnels
  - o BRNN
  - o BLSTM
  - MDLSTM

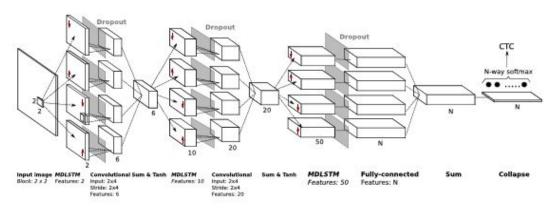
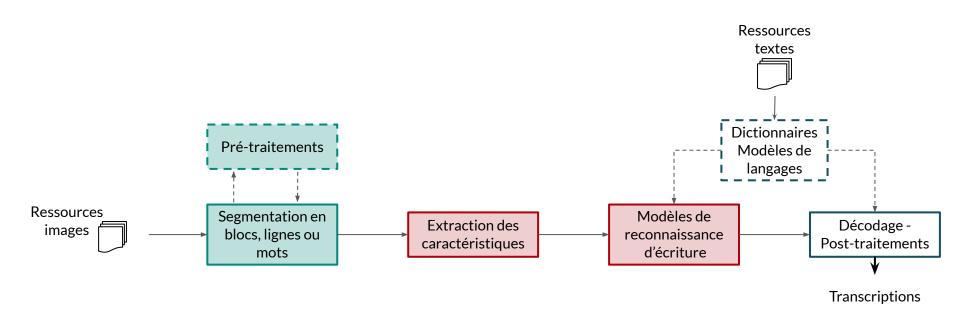


Fig. 1. The Recurrent Neural Network considered in this paper, with the places where dropout can be applied.

#### Sommaire



CTC: Connexionist Temporal Classification (A. Graves 2006,2009)

Créé pour des tâches de classifications temporels ⇒ problèmes d'étiquetages de séquences où l'alignement est inconnu entre l'entrée et la sortie du système

Pré-traitement des données d'entrée ou post-traitement des données en sortie du réseau : inutile

Prédit une séquence de caractères  $\pi$  pour une séquence d'entrée noté x où  $y_{\pi t}^{t}$  est la probabilité d'observer l'étiquette  $\pi$  à l'instant t

$$\mathbb{P}(\pi|x) = \prod_{t=1}^{T} \mathbb{P}(\pi_t|x,t) = \prod_{t=1}^{T} y_{\pi_t}^t$$

#### Caractéristiques:

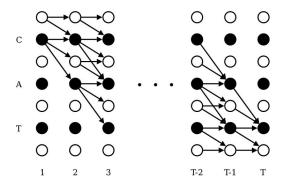
- Unique couche de neurones de type Softmax
- |L| neurones où un neurone correspond à une classe
- +1 neurone "joker" appelé blank

Apprentissage : algorithme forward-backward modifié pour intégrer le label blank dans la séquence de label attendue

⇒ insertion du blank au début, à la fin et entre chaque caractère d'un label :

 $cat \Rightarrow blcblabltbl$ 

$$|I'| = 2 * |I| + 1$$



Apprentissage : algorithme forward-backward modifié pour intégrer le label blank dans la séquence de label attendue

• insertion du blank au début, à la fin et entre chaque caractère d'un label

une entrée → plusieurs séquences différentes

 ajout d'une fonction surjective pour supprimer les répétitions de caractères non séparées par un blank puis supprimer les blank

```
{__SSS_o _ ppp_hh_i_ee___} devient {Sophie}
```

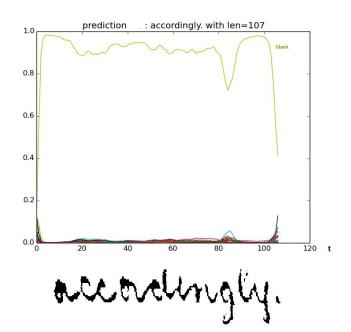
• la probabilité de la séquence d'étiquettes finale l est calculée à partir de l'ensemble des chemins possibles  $\mathbb{P}(l|x) = \prod \mathbb{P}(\pi|x)$ 

#### Décodage:

- le meilleur chemin
- par recherche de préfixe

⇒ utilisation de dictionnaires et modèles de langues : apprentissage et décodage

#### Visualisation du CTC pendant l'apprentissage:



Prédiction du mot "accordingly": Itération 0

Prédiction du mot "accordingly": Itération 20

: accordingly. with len=107

prediction

0.8

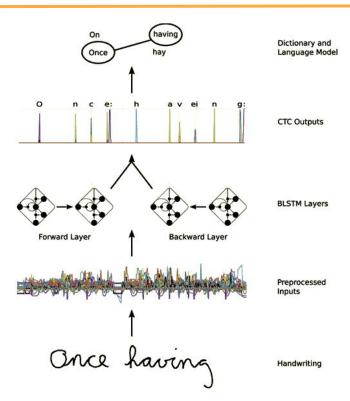
0.6

0.4

0.2

67

120 t

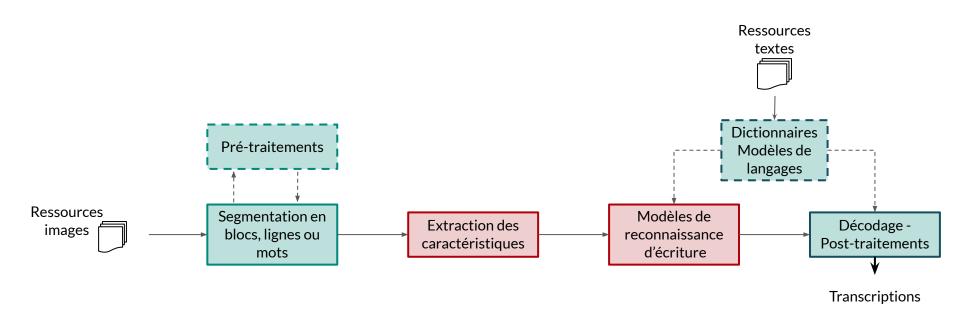


#### Modélisation du langage

Sortie des réseaux imparfaite ⇒ possibilité de la contraindre avec TAL

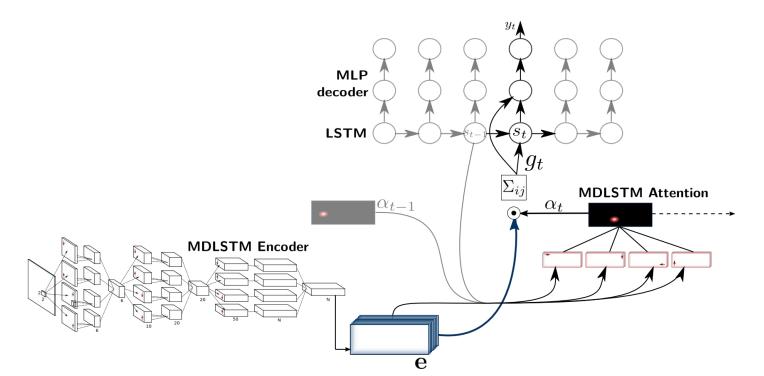
- les dictionnaires : vocabulaires des documents étudiés, de la langue ou
   Wikipedia ⇒ problème évolution de la langue donc mots hors-vocabulaire
- les modèles probabilistes : les n-grammes, les multi-grammes
- les approches neuronales :
  - o large vocabulaire : HMM/ANN montre de meilleurs résultats qu'un BLSTM

#### Sommaire



# Un peu plus loin:

T. Bluche: reconnaissance de paragraphes



### Objectifs

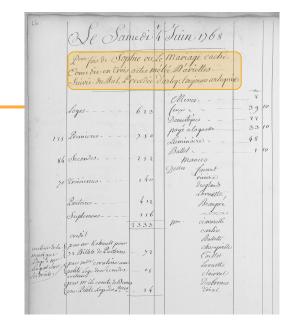
Vous êtes sur un nouveau projet, avec une toute nouvelle collection de documents manuscrits à étudier, quelle solution est envisageable ?



- définition d'un nouveau système de reconnaissance d' écriture dédié
- spécialisation d'un système existant avec un échantillon des données
- une autre option?

Étudier et analyser automatiquement les titres des comptes quotidiens

⇒ Sans vérité terrain



## Objectifs

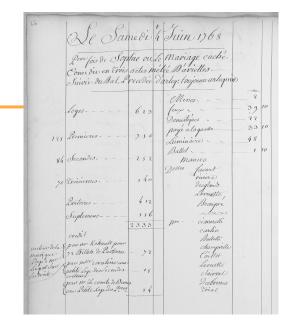
Vous êtes sur un nouveau projet, avec une toute nouvelle collection de documents manuscrits à étudier, quelle solution est envisageable ?



- définition d'un nouveau système de reconnaissance d' écriture dédié
- spécialisation d'un système existant avec un échantillon des données
- Apprentissage par transfert de connaissances

Étudier et analyser automatiquement les titres des comptes quotidiens

⇒ Sans vérité terrain



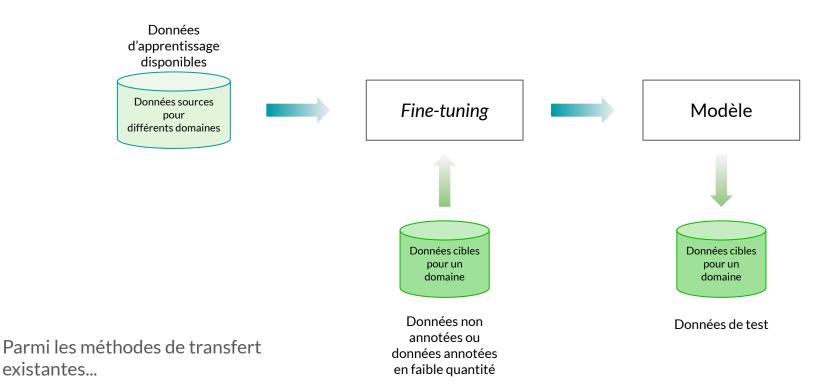
### Apprentissage par Transfert de Connaissances (ATC)



### Apprentissage par Transfert de Connaissances (ATC)



# Apprentissage par Transfert de Connaissances (ATC)



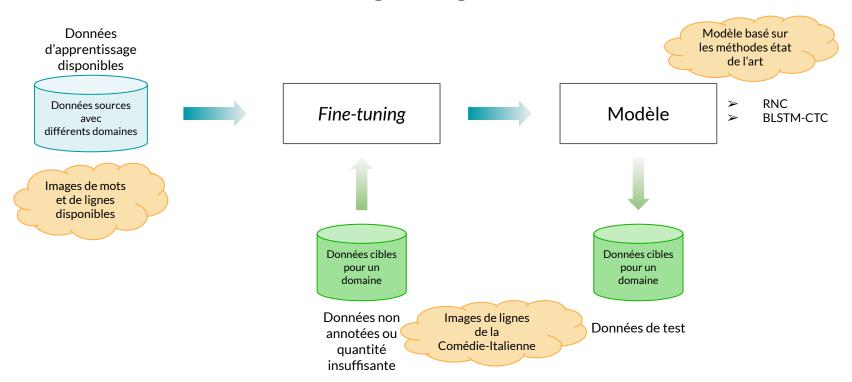
14

# Discussion(s)

# Application du ATC sur les registres de CI

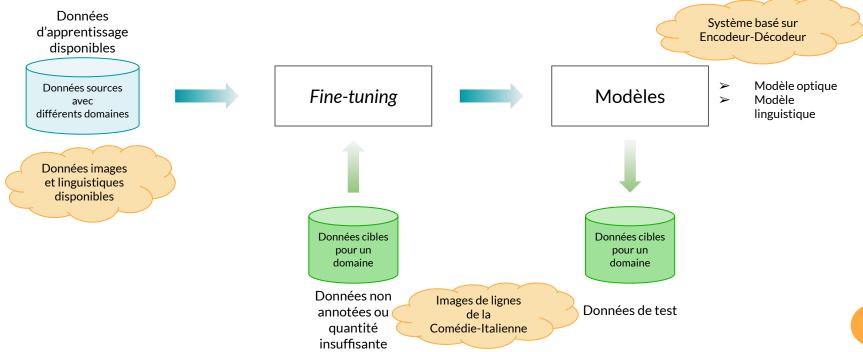
### ATC appliqué à notre étude

Une tâche donnée → annoter les images de lignes de titres de la Comédie-Italienne



### ATC appliqué à notre étude : nouveau modèle

Une tâche donnée → annoter les images de lignes de titres de la Comédie-Italienne décomposer le problème en 2 modèles



# Pour la suite, slides de soutenance